Санкт-Петербургский Политехнический Университет
Высшая школа прикладной математики и вычислительной физики, ФизМех
01.03.02 Прикладная математика и информатика

Отчет по лабораторной работе № 3
"Боксплот Тьюки и анализ выбросов"

Выполнил студент гр. 5030102/30201 Аулова М. В.
Преподаватель Баженов А. Н.

Санкт-Петербург
2025

Постановка задачи

Задание:
1. Сгенерировать выборки объёмом n = 20,100. Построить боксплот Тьюки.
2. Определить долю выбросов экспериментально: для каждого распределения сгенерировать 1000 выборок заданного объёма, вычислить среднюю долю выбросов.

Цели и задачи:
Научиться применять боксплот Тьюки в обработке и анализе одномерных распределений.
Проанализировать, как размер выборки влияет на долю отсеиваемых аномальных значений.

Исследуются следующие распределения:
1. Нормальное $N(x;0,1)$
2. Коши $C(x;0,1)$
3. Лапласа $L(x;0, 1/\sqrt{2})$
4. Пуассона $P(k;10)$
5. Равномерное $U(x;-\sqrt{3},\sqrt{3})$

Теоретическая часть

- Нормальное распределение

$$Normal(x, 0{,}1) = \frac{1}{\sqrt{2\pi}} e^{\frac{-x^2}{2}}$$

- Распределение Коши

$$Cauchy(x, 0{,}1) = \frac{1}{\pi} \frac{1}{x^2 + 1}$$

- Распределение Лапласса

$$Laplace\ (x, 0, \frac{1}{\sqrt{2}}) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}$$

- Распределение Пуассона

$$Poisson(k, 10) = \frac{10^k}{k!} e^{-10}$$

- Равномерное распределение

$$Uniform(x, -\sqrt{3}, \sqrt{3}) = \begin{cases} \frac{1}{2\sqrt{3}} \text{ при } |x| \leq \sqrt{3} \\ 0 \text{ при } |x| > \sqrt{3} \end{cases}$$

Реализация

Язык программирования: Python 3.12

Сторонние библиотеки:
numpy – генерация случайных выборок
matplotlib.pyplot – построение графиков

Код: https://github.com/Maria9950/MatStat/blob/master/lab3/lab3.py

Результаты

n = 20

Распределение	Средняя доля выбросов	Стандартное отклонение
Нормальное	2.37%	4.47%
Коши	15.11%	7.42%
Лапласа	7.39%	6.56%
Пуассона	2.10%	4.08%
Равномерное	0.23%	1.40%

n = 100

Распределение	Средняя доля выбросов	Стандартное отклонение
Нормальное	1.03%	1.26%
Коши	15.46%	3.34%
Лапласа	6.45%	3.10%
Пуассона	1.04%	1.60%
Равномерное	0.00%	0.00%

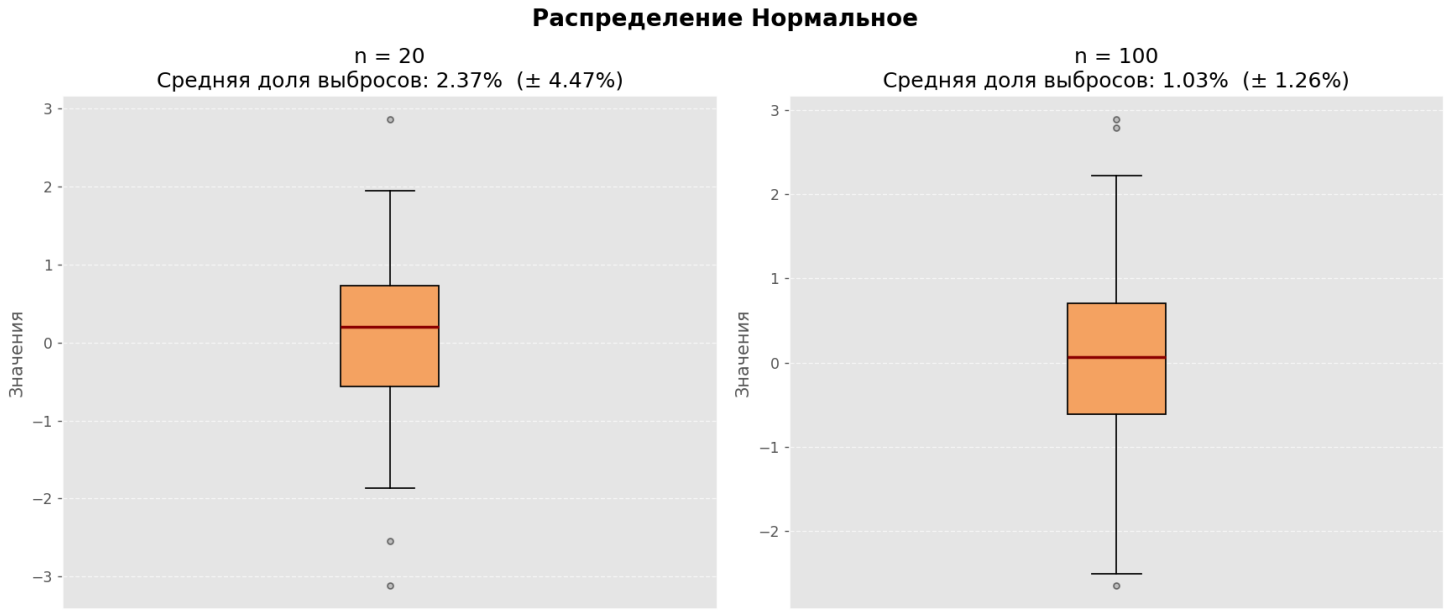

Распределение Коши

n = 20
Средняя доля выбросов: 15.11% (± 7.42%)

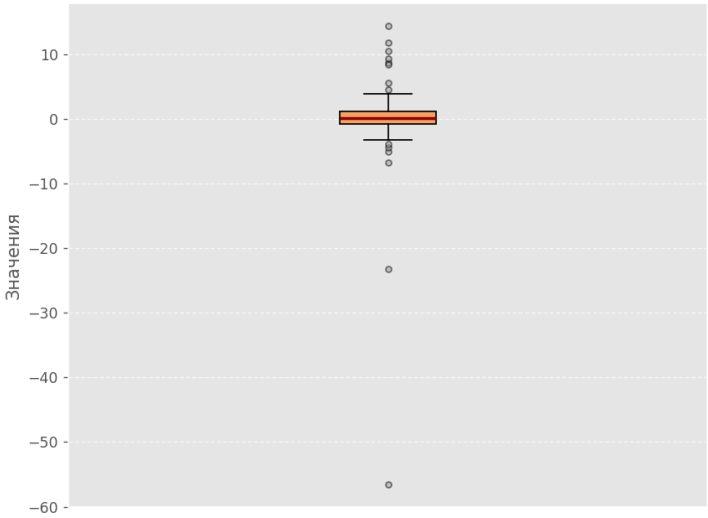

n = 100
Средняя доля выбросов: 15.46% (± 3.34%)

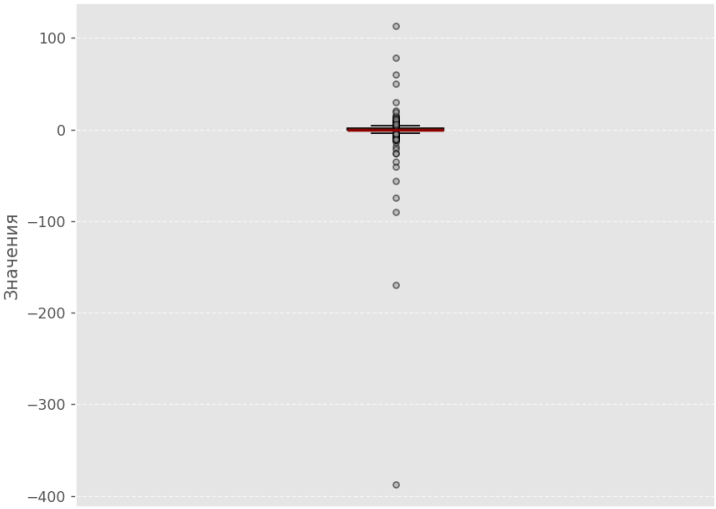

Распределение Лапласа

n = 20
Средняя доля выбросов: 7.39% (± 6.56%)

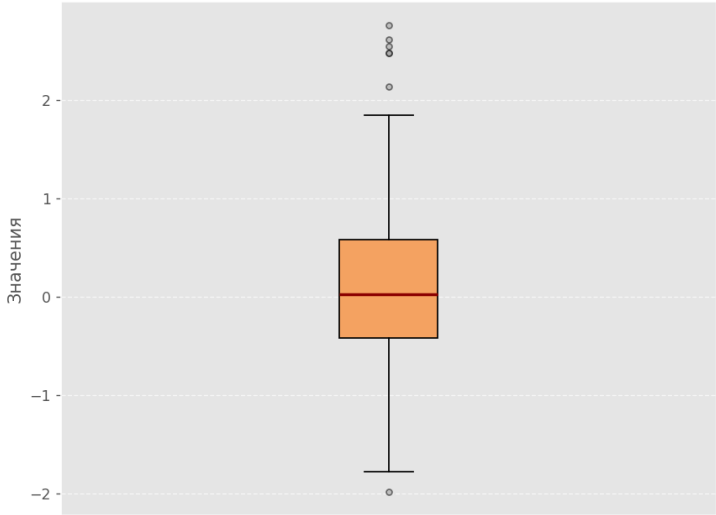

n = 100
Средняя доля выбросов: 6.45% (± 3.10%)

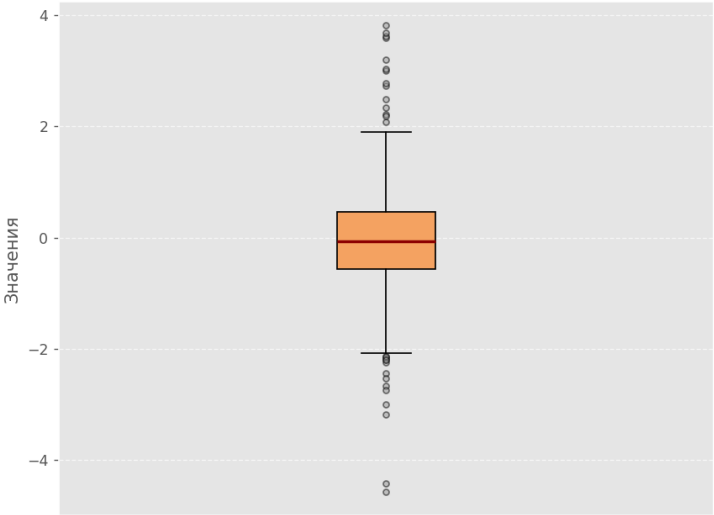

Распределение Пуассона

n = 20
Средняя доля выбросов: 2.10% (± 4.08%)

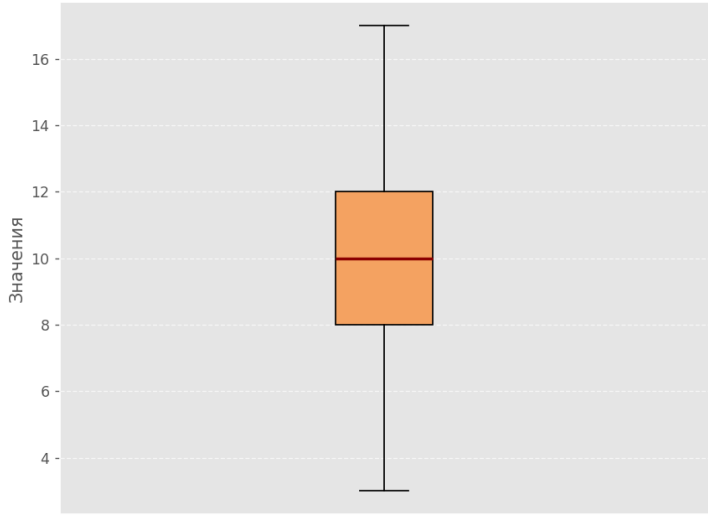

n = 100
Средняя доля выбросов: 1.04% (± 1.60%)

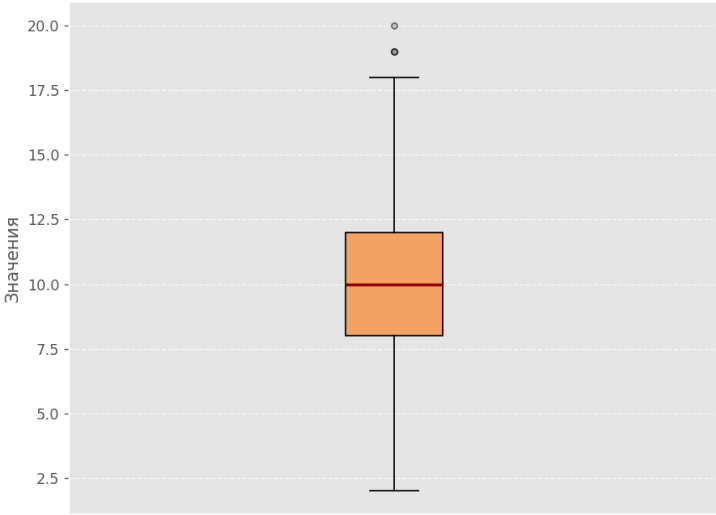

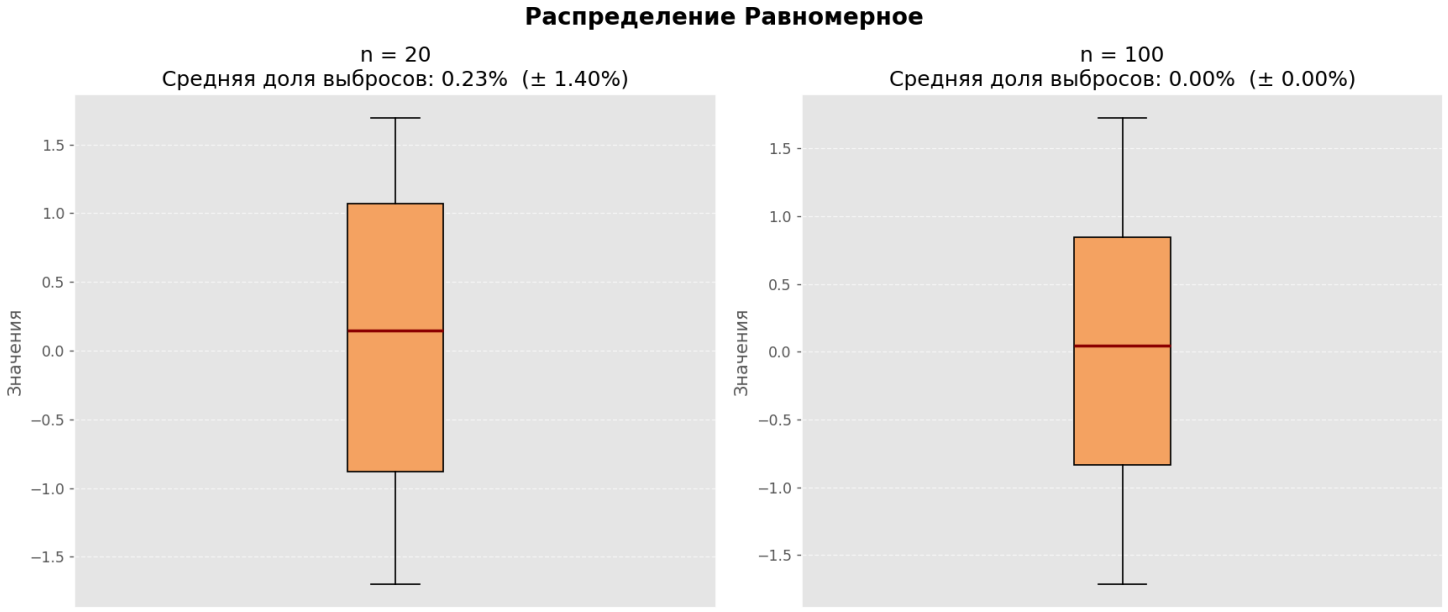
Распределение Равномерное
n = 20
Средняя доля выбросов: 0.23% (± 1.40%)
n = 100
Средняя доля выбросов: 0.00% (± 0.00%)
Значения
1.5
1.0
0.5
0.0
−0.5
−1.0
−1.5

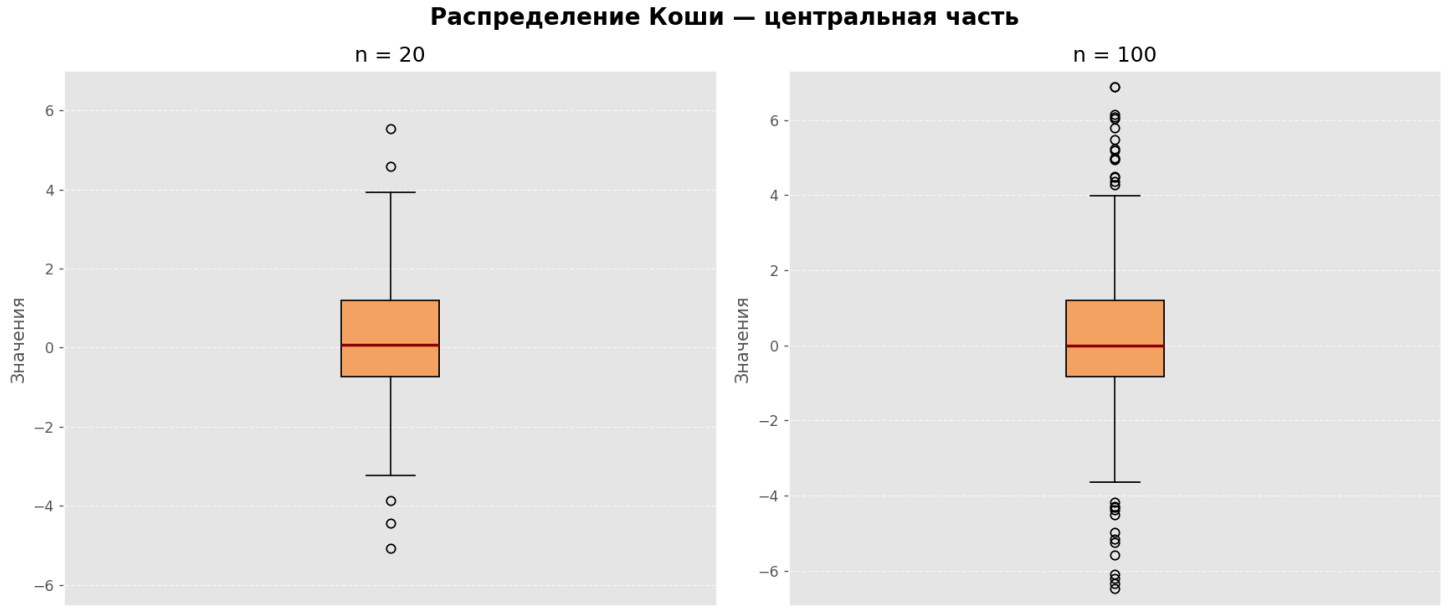
Распределение Коши — центральная часть
n = 20
n = 100
Значения
6
4
2
0
−2
−4
−6

Обсуждение

Увеличение объёма выборки с n=20 до n=100 по-разному влияет на долю обнаруживаемых выбросов для различных распределений.

Нормальное, Лапласа, Пуассона и равномерное распределения.
Для этих распределений при увеличении объёма выборки наблюдается уменьшение средней доли выбросов (нормальное: 2.37% → 1.03%; Лапласа: 7.39% → 6.45%; Пуассона: 2.10% → 1.04%; равномерное: 0.23% → 0.00%). Одновременно снижается стандартное отклонение, что свидетельствует о большей устойчивости и стабильности оценки при большем количестве наблюдений.

Распределение Коши.
Для распределения Коши средняя доля выбросов практически не изменяется (15.11% → 15.46%). Несмотря на некоторое уменьшение стандартного отклонения (с 7.42% до 3.34%), высокая доля выбросов сохраняется. Это объясняется наличием тяжёлых хвостов у данного распределения, из-за чего экстремальные значения появляются независимо от увеличения размера выборки.

Таким образом, при увеличении объёма выборки для распределений с лёгкими или умеренными хвостами наблюдается уменьшение доли выбросов и повышение стабильности результатов. В случае распределения с тяжёлыми хвостами, такого как распределение Коши, изменение размера выборки практически не влияет на среднюю долю выбросов.

Выводы

В ходе лабораторной работы были построены боксплоты Тьюки, которые позволили наглядно проанализировать особенности каждого распределения. Проведённый эксперимент показал, что доля выбросов определяется характером распределения. Наименьшее количество выбросов наблюдается у равномерного распределения (практически 0%), тогда как наибольшее — у распределения Коши (около 15%). Распределение Лапласа занимает промежуточное положение (примерно 6–7%), что связано с более тяжёлыми хвостами по сравнению с нормальным распределением, но менее выраженными, чем у распределения Коши.

Также было исследовано влияние размера выборки. При увеличении объёма выборки с n=20 до n=100 уменьшается разброс оценок доли выбросов для всех рассмотренных распределений. Для распределений с лёгкими хвостами (нормального, равномерного и распределения Пуассона), а также для распределения Лапласа наблюдается уменьшение самой доли выбросов. В случае распределения Коши этот показатель остаётся практически неизменным.

Полученные результаты подтверждают практическую ценность боксплота как удобного средства для первичного анализа данных.