Санкт-Петербургский Политехнический Университет
Высшая школа прикладной математики и вычислительной физики, ФизМех
01.03.02 Прикладная математика и информатика

Отчет по лабораторной работе № 4
"Эмпирическая функция распределения и ядерные оценки плотности"

Выполнил студент гр. 5030102/30201 Аулова М. В.
Преподаватель Баженов А. Н.

Санкт-Петербург
2025

Постановка задачи

Задание:
Сгенерировать выборки объёмом n = 20,60,100. Построить на них:
1. Эмпирическую функцию распределения (э. ф. р.) и теоретическую функцию распределения.
2. Ядерную оценку плотности (ядро — гауссово) и теоретическую плотность.
Выполнить 1-2 на отрезке [−4,4] для непрерывных распределений и на отрезке [6, 14] для распределения Пуассона.

Цели и задачи:
• Сделать вывод о том, как мощность выборки влияет на приближение эмпирической функции к истинной функции распределения.
• Сравнить два способа оценки плотности распределения: ядерные оценки и гистограммы.

Исследуются следующие распределения:
1. Нормальное N(x;0,1)
2. Коши C(x;0,1)
3. Лапласа L(x;0, 1/√2)
4. Пуассона P(k;10)
5. Равномерное U(x;−√3,√3)

Теоретическая часть

- Нормальное распределение

$$Normal(x, 0,1) = \frac{1}{\sqrt{2\pi}} e^{\frac{-x^2}{2}}$$

- Распределение Коши

$$Cauchy(x, 0,1) = \frac{1}{\pi} \frac{1}{x^2 + 1}$$

- Распределение Лапласса

$$Laplace\ (x, 0, \frac{1}{\sqrt{2}}) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}$$

- Распределение Пуассона

$$Poisson(k, 10) = \frac{10^k}{k!} e^{-10}$$

- Равномерное распределение

$$Uniform(x, -\sqrt{3}, \sqrt{3}) = \begin{cases} \frac{1}{2\sqrt{3}} \text{ при } |x| \leq \sqrt{3} \\ 0 \text{ при } |x| > \sqrt{3} \end{cases}$$

Пусть дана выборка независимых одинаково распределённых случайных величин $X_1, X_2, \dots, X_n$.
Эмпирическая функция распределения (э.ф.р.) определяется формулой:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}\{X_i \leq x\},$$

где $\mathbf{1}\{X_i \leq x\}$— индикаторная функция, равная 1, если $X_i \leq x$, и 0 в противном случае.
Эмпирическая функция распределения является **ступенчатой неубывающей функцией**, принимающей значения от 0 до 1.
Согласно теореме Гливенко–Кантелли, эмпирическая функция распределения сходится по вероятности к истинной функции распределения:

$$\sup_x |F_n(x) - F(x)| \xrightarrow[n\to\infty]{P} 0.$$

Это означает, что при увеличении объёма выборки эмпирическая функция всё точнее приближает теоретическую функцию распределения.

Ядерная оценка плотности распределения
Для получения более гладкой оценки используется ядерная оценка плотности, которая определяется формулой:

$$f_n(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right),$$

где

- $K(\cdot)$— ядерная функция,
- $h > 0$— параметр сглаживания (ширина окна).

В данной работе используется **гауссово ядро**:

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2}.$$

Ядерная оценка плотности является гладкой функцией, что позволяет лучше аппроксимировать истинную плотность распределения, особенно при небольших объёмах выборки.

Правило Сильвермана

Для практического выбора параметра сглаживания часто используется правило Сильвермана, которое минимизирует асимптотическую среднеквадратичную ошибку при предположении близости распределения к нормальному.

Параметр сглаживания вычисляется по формуле:

$$h = 1.06\, \sigma\, n^{-1/5},$$

где:

- σ— среднеквадратичное отклонение,
- n— объём выборки.

Робастная модификация правила Сильвермана

Для распределений с тяжёлыми хвостами (Коши) стандартное отклонение может быть неустойчивой характеристикой. В таких случаях используется робастная модификация правила Сильвермана, основанная на межквартильном размахе.

Параметр сглаживания определяется формулой:

$$h = 0.9 \cdot \min\left(\sigma, \frac{\mathrm{IQR}}{1.34}\right) \cdot n^{-1/5},$$

где:

- $\mathrm{IQR} = Q_3 - Q_1$— межквартильный размах,

Использование минимального значения между σи $\mathrm{IQR}/1.34$ позволяет снизить влияние выбросов и обеспечивает более устойчивую оценку плотности.

Влияние параметра сглаживания на оценку плотности

- При слишком малых значениях h ядерная оценка становится излишне неровной и отражает шум выборки.
- При слишком больших значениях h происходит чрезмерное сглаживание, что приводит к потере локальных особенностей распределения.

Реализация

Язык программирования: Python 3.12

Сторонние библиотеки:
numpy – генерация случайных выборок
matplotlib.pyplot – построение графиков
scipy.stats – теоретические распределения

Код: https://github.com/Maria9950/MatStat/blob/master/lab4/lab4.py

Результаты

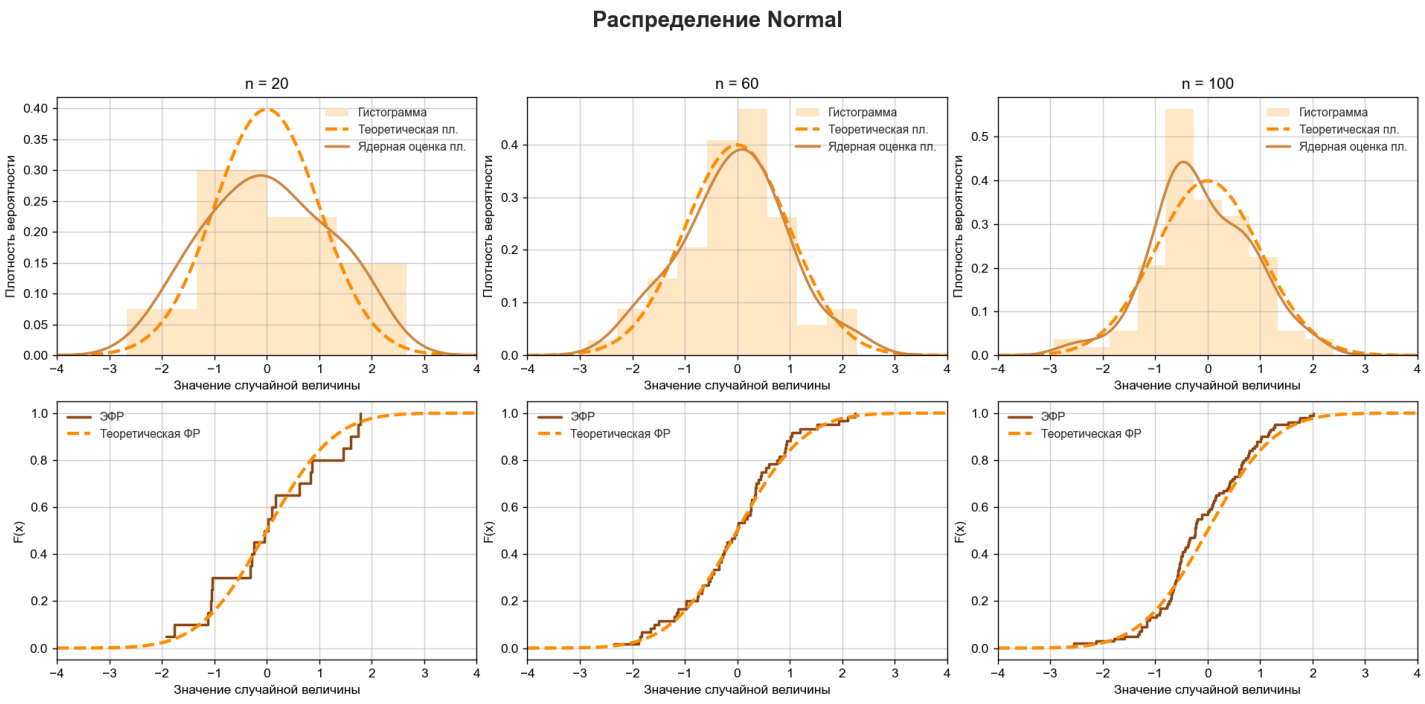
Распределение Normal
n = 20
n = 60
n = 100
Гистограмма
Теоретическая пл.
Ядерная оценка пл.
Плотность вероятности
Значение случайной величины
ЭФР
Теоретическая ФР
F(x)

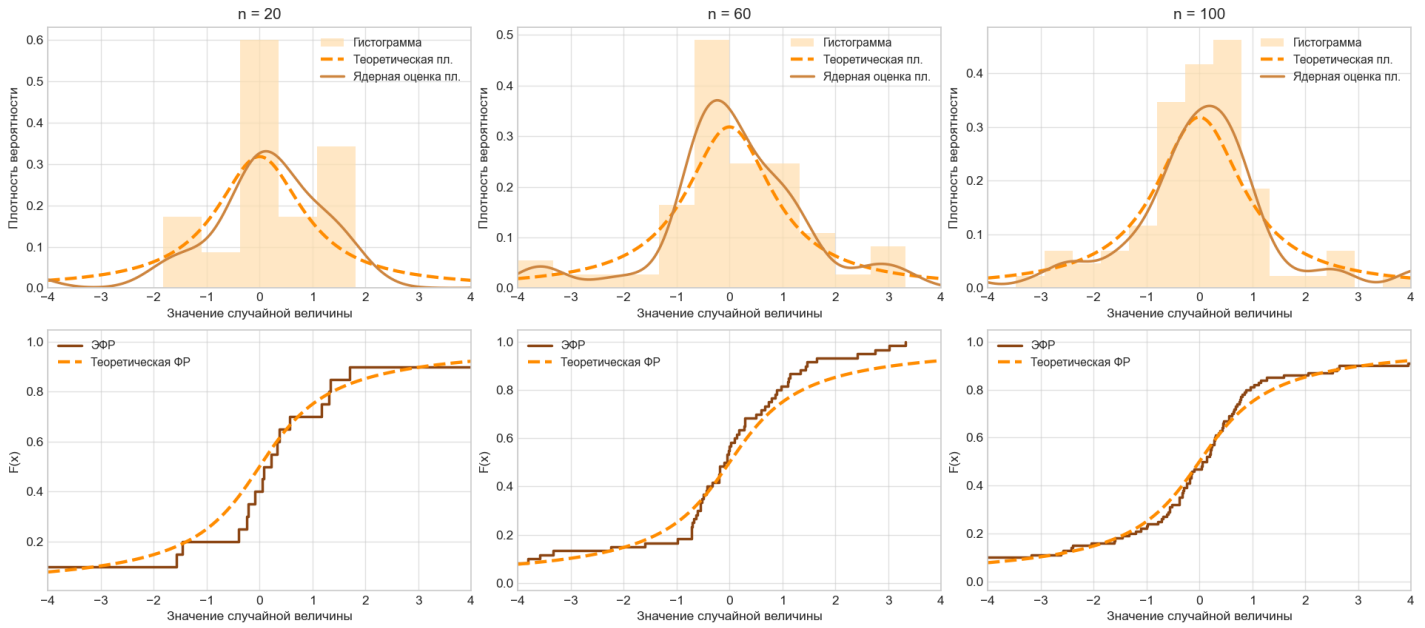
Распределение Cauchy
n = 20
n = 60
n = 100
Гистограмма
Теоретическая пл.
Ядерная оценка пл.
Плотность вероятности
Значение случайной величины
ЭФР
Теоретическая ФР
F(x)

Распределение Laplace

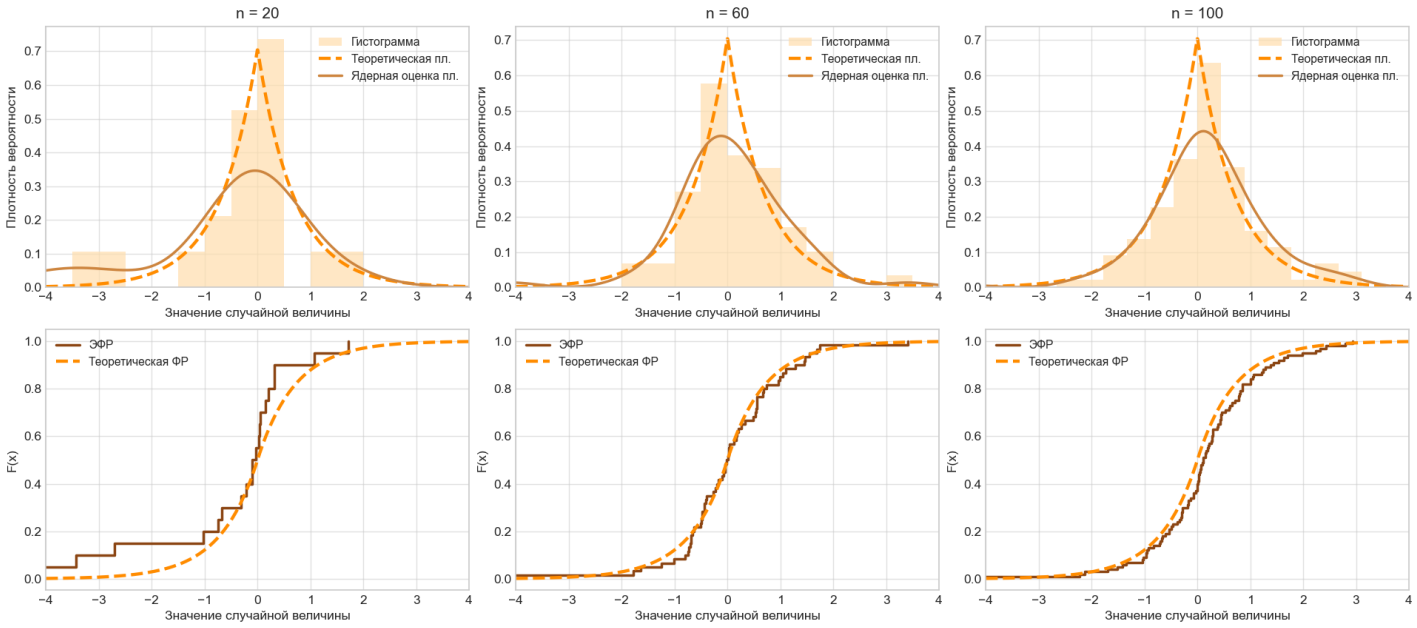

Распределение Poisson

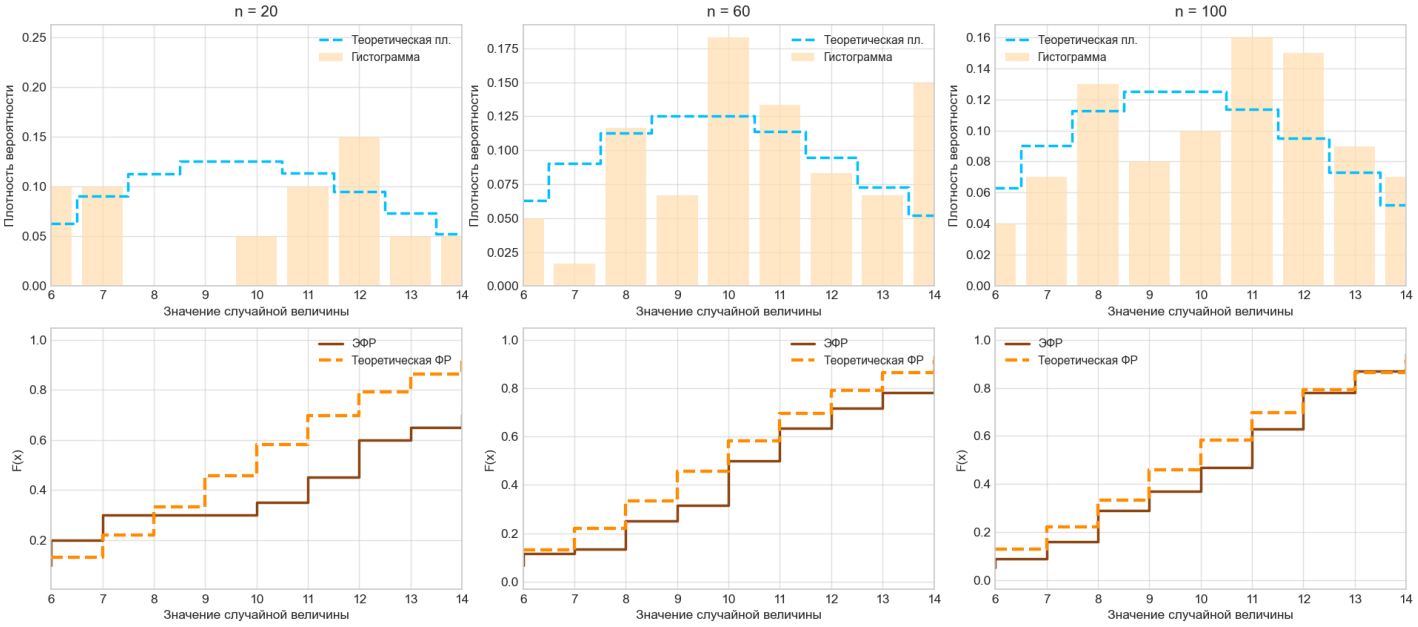

Распределение Uniform

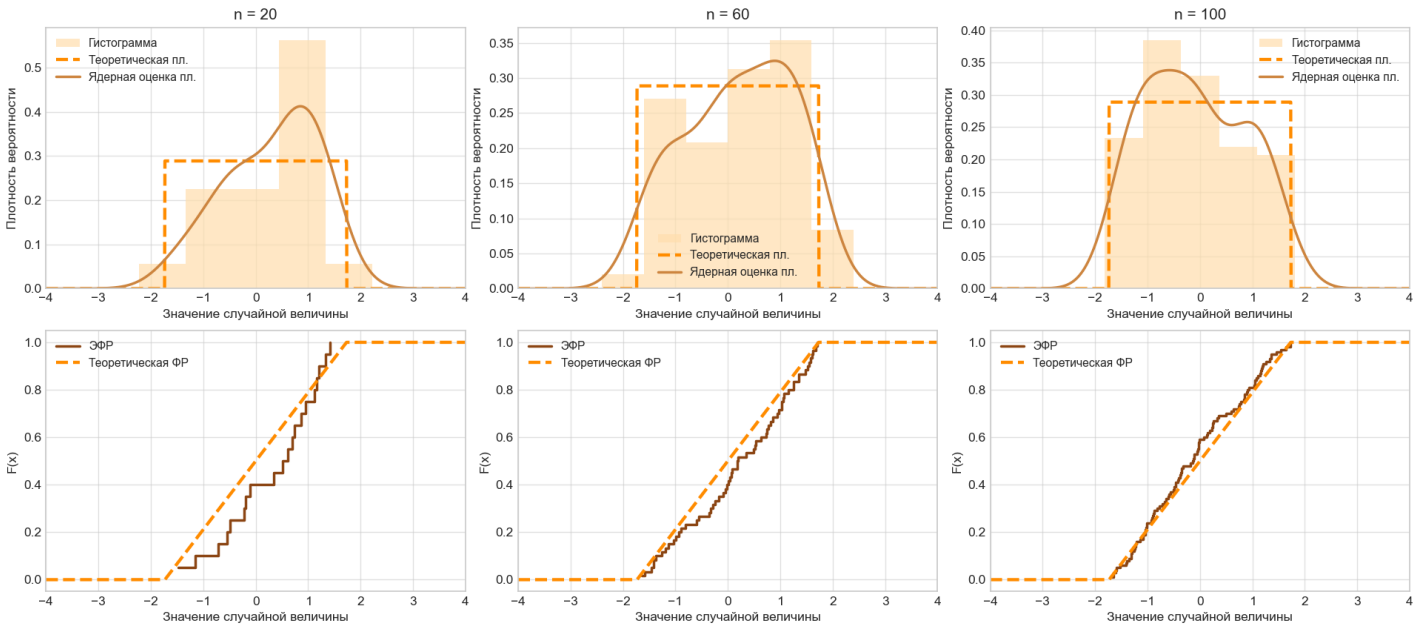

Обсуждение

В ходе лабораторной работы были исследованы свойства эмпирической функции распределения и различных способов оценки плотности вероятности для выборок разного объёма. Построенные графики позволяют проследить, как увеличение числа наблюдений влияет на точность приближения эмпирических характеристик к теоретическим.

Эмпирическая функция распределения имеет ступенчатый вид, причём форма этих ступеней зависит от размера выборки. При небольшом числе наблюдений (n=20n = 20n=20) ступени выражены более резко, а различия между эмпирической и теоретической функциями распределения заметны для всех рассмотренных распределений. Это связано с недостаточным числом данных для приближения истинной функции распределения.

С увеличением объёма выборки до n=60 и n=100 эмпирическая функция распределения становится более плавной и начинает лучше совпадать с теоретической кривой. Расхождения между ними уменьшаются, и для большинства распределений при n=100 наблюдается достаточно хорошее соответствие. Наиболее заметные отклонения сохраняются для распределения Коши, что объясняется его тяжёлыми хвостами и высокой чувствительностью к экстремальным значениям.

При анализе оценок плотности вероятности можно увидеть различия между гистограммной оценкой и ядерным сглаживанием. Гистограмма зависит от выбора числа интервалов и при малом объёме выборки имеет выраженную ступенчатую форму, что может искажать реальную форму плотности распределения. С ростом числа наблюдений гистограмма становится более устойчивой и начинает лучше отражать теоретическую плотность.

Ядерная оценка плотности с гауссовым ядром даёт более гладкую аппроксимацию распределения. Для непрерывных распределений она достаточно хорошо повторяет форму теоретической плотности уже при средних объёмах выборки. При этом для распределения Коши из-за тяжёлых хвостов сглаженная оценка может демонстрировать большие отклонения от теоретической кривой.

Таким образом, результаты эксперимента показывают, что увеличение объёма выборки улучшает точность приближения как эмпирической функции распределения, так и оценок плотности. Ядерное сглаживание позволяет получить более гладкую и информативную оценку плотности по сравнению с гистограммой, однако при малых выборках и распределениях с тяжёлыми хвостами влияние случайных колебаний данных остаётся заметным.

Выводы

1. При увеличении размера выборки эмпирическая функция распределения всё ближе соответствует теоретической. Однако для распределений с тяжёлыми хвостами, таких как распределение Коши, даже выборка объёма n=100 может давать заметные отклонения и не обеспечивает полной устойчивости оценки.
2. Гистограмма даёт ступенчатую оценку, хорошо работающую при больших выборках или для дискретных распределений. Ядерная оценка плотности, напротив, обеспечивает более плавное приближение и, как правило, точнее передаёт форму истинной плотности, особенно при сравнительно небольших объёмах выборки.