Санкт-Петербургский Политехнический Университет
Высшая школа прикладной математики и вычислительной физики, ФизМех
01.03.02 Прикладная математика и информатика

Отчет по лабораторной работе № 5
"Корреляционный анализ и эллипсы рассеивания"

Выполнил студент гр. 5030102/30201 Аулова М. В.
Преподаватель Баженов А. Н.

Санкт-Петербург
2026

Постановка задачи

Задание: Сгенерировать двумерные выборки (x, y) объёмом n = 20, 60, 100 из:

- Двумерного нормального распределения N(0,0,1,1, ρ), где ρ = 0, 0.5, 0.9
- Смеси 0.9 N(0,0,1,1, 0.9) + 0.1 N(0,0,10,10, -0.9).

Для каждой выборки:

1. Вычислить коэффициенты корреляции Пирсона, Спирмена и квадратный. Повторить 1000 раз, найти средние и диспресии
2. Построить диаграммы рассеяния и эллипсы равновероятности.

Цели и задачи:

• Сравнить исходное заначение коэффициента корреляции с вычисленными.
• Изучить способы визуализации ковариационной структуры данных.

Теоретическая часть

- Двумерное нормальное распрededение

$$N\left(x, y, \bar{x}, \bar{y}, \sigma_x, \sigma_y, \rho\right) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}}\exp(-\frac{1}{2(1-\rho^2)}(\frac{(x-\bar{x})^2}{{\sigma_x}^2} - 2\frac{(x-\bar{x})(y-\bar{y})}{\sigma_x\sigma_y} + \frac{(y-\bar{y})^2}{{\sigma_y}^2}))$$

- Корреляционный момент(ковариация)

$$K = cov(X, Y) = M[(X-\bar{x})(Y-\bar{y})]$$

- Коэффициент корреляции

$$\rho = \frac{K}{\sigma_x\,\sigma_y}$$

- Выборочный коэффициент корреляции Пирсона

$$r = \frac{\frac{1}{n}\sum(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\frac{1}{n}\sum(x_i-\bar{x})^2\frac{1}{n}\sum(y_i-\bar{y})^2}} = \frac{K}{s_X s_Y}$$

- Выборочный коэффициент раноговой корреляции Спирмена

$$r_S = \frac{\frac{1}{n}\sum(u_i-\bar{u})(v_i-\bar{v})}{\sqrt{\frac{1}{n}\sum(u_i-\bar{u})^2\frac{1}{n}\sum(v_i-\bar{v})^2}}$$

- Выборочный квадратный коэффициент корреляции

$$r_Q = \frac{(n_1+n_3)-(n_2+n_4)}{n}$$

Реализация

Язык программирования: Python 3.14

Сторонние библиотеки:
numpy – генерация случайных выборок
matplotlib.pyplot – построение графиков
scipy.stats – теоретические распределения

Код: https://github.com/Maria9950/MatStat/tree/master/lab4

Результаты

Двумерное нормальное распределение, ρ = 0, n = 20
Выборка
Эллипс
Центр
X
Y

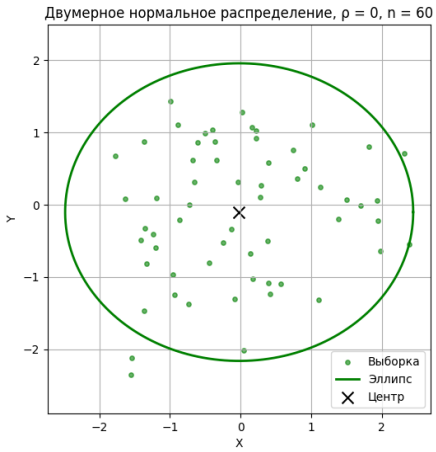
Двумерное нормальное распределение, ρ = 0, n = 60
Выборка
Эллипс
Центр
X
Y

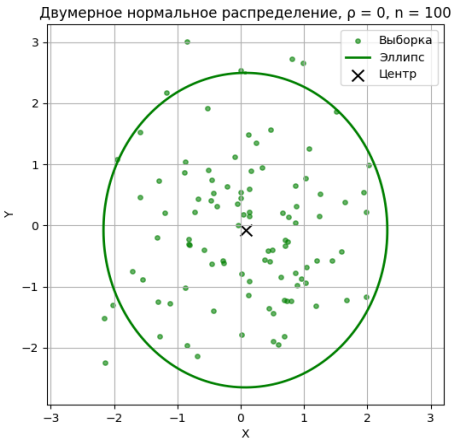
Двумерное нормальное распределение, ρ = 0, n = 100
Выборка
Эллипс
Центр
X
Y

Двумерное нормальное распределение, ρ = 0.5, n = 20
Выборка
Эллипс
Центр
X
Y

Двумерное нормальное распределение, ρ = 0.5, n = 60
Выборка
Эллипс
Центр
X
Y

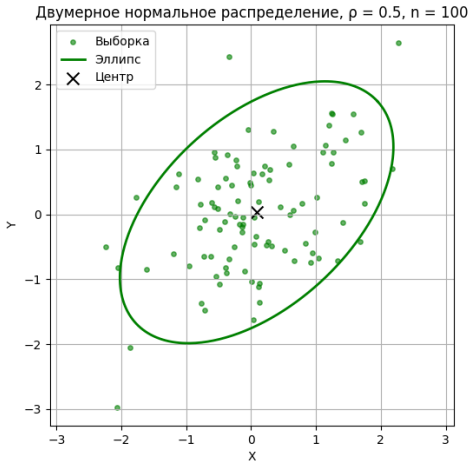
Двумерное нормальное распределение, ρ = 0.5, n = 100
Выборка
Эллипс
Центр
X
Y

Двумерное нормальное распределение, ρ = 0.9, n = 20
Выборка
Эллипс
Центр
X
Y

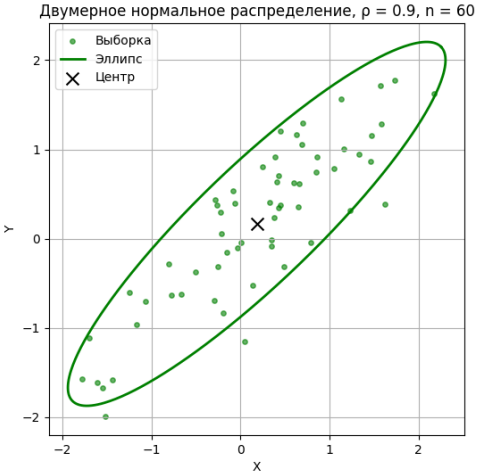
Двумерное нормальное распределение, ρ = 0.9, n = 60
Выборка
Эллипс
Центр
X
Y

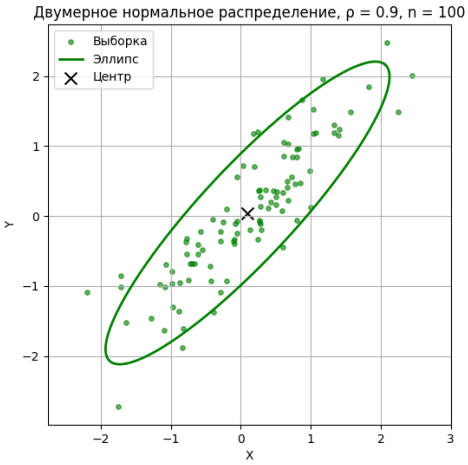
Двумерное нормальное распределение, ρ = 0.9, n = 100
Выборка
Эллипс
Центр
X
Y

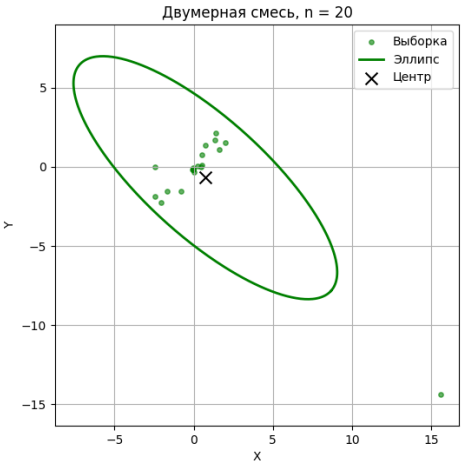
Двумерная смесь, n = 20
Выборка
Эллипс
Центр
X
Y

Двумерная смесь, n = 60
Выборка
Эллипс
Центр
X
Y

Двумерная смесь, n = 100
Выборка
Эллипс
Центр
X
Y

	Выборка	Средний Пирсон	Дисперсия Пирсона	Отклонение от заданного	Средний Спирмен	Дисперсия Спирмена	Отклонение от заданного	Средний квадратный	Дисперсия квадратного	Отклонение от заданного
Двумерное нормальное распределение	n=20, ρ=0	-0.0068	0.0517	0.0068	-0.0032	0.0519	0.0032	0.0004	0.0521	0.0004
	n=60, ρ=0	0.0007	0.0163	0.0007	0.0047	0.0158	0.0047	0.0065	0.0162	0.0065
	n=100, ρ=0	0.0002	0.0108	0.0002	0.0001	0.0106	0.0001	-0.0014	0.0099	0.0014
	n=20, ρ=0.5	0.4979	0.0303	0.0021	0.4703	0.0330	0.0297	0.3318	0.0454	0.1682
	n=60, ρ=0.5	0.4980	0.0097	0.0020	0.4790	0.0105	0.0210	0.3340	0.0148	0.1660
	n=100, ρ=0.5	0.5017	0.0054	0.0017	0.4818	0.0060	0.0182	0.3327	0.0087	0.1673
	n=20, ρ=0.9	0.8953	0.0024	0.0047	0.8647	0.0048	0.0353	0.6890	0.0269	0.2110
	n=60, ρ=0.9	0.8991	0.0007	0.0009	0.8847	0.0011	0.0153	0.7091	0.0081	0.1909
	n=100, ρ=0.9	0.8987	0.0004	0.0013	0.8860	0.0006	0.0140	0.7079	0.0049	0.1921
Двумерная смесь	n=20	-0.3419	0.4195	0.4095	0.4686	0.0727	1.2200	0.5324	0.0369	1.2838
	n=60	-0.6430	0.0894	0.1084	0.4736	0.0279	1.2250	0.5608	0.0105	1.3122
	n=100	-0.6929	0.0318	0.0585	0.4728	0.0166	1.2242	0.5593	0.0066	1.3107

Обсуждение

- Двумерное нормальное распределение

1) При $\rho = 0$ все коэффициенты корреляции имеют средние значения, близкие к нулю, что соответствует теоретическому ожиданию. Дисперсии уменьшаются с ростом объёма выборки, что свидетельствует о повышении устойчивости оценок.
2) При $\rho = 0.5$ коэффициент Пирсона наиболее точно отражает заданную линейную зависимость. Коэффициент Спирмена даёт несколько заниженную оценку, так как измеряет монотонную зависимость. Квадрантный коэффициент существенно меньше, поскольку основан на знаках отклонений и является более грубой оценкой.
   При $\rho = 0.9$ коэффициент Пирсона практически совпадает с заданным значением. Спирмен остаётся немного ниже, а квадрантный существенно меньше. С увеличением объёма выборки дисперсии всех коэффициентов уменьшаются, что подтверждает их сходимость.

- Двумерная смесь распределений

1) В результате моделирования установлено, что средний коэффициент корреляции Пирсона принимает отрицательные значения (от -0.34 при $n = 20$ до -0.69 при $n = 100$) и с увеличением объёма выборки стабилизируется. Это свидетельствует о наличии отрицательной линейной зависимости, формируемой влиянием выбросов с большой дисперсией.
2) Коэффициенты Спирмена и квадрантный во всех экспериментах принимают положительные значения (примерно 0.47 и 0.55 соответственно) и практически не зависят от объёма выборки. Это объясняется тем, что данные коэффициенты менее чувствительны к выбросам и отражают структуру основной массы выборки, в которой преобладает положительная зависимость.
3) Наблюдается существенное расхождение между коэффициентом Пирсона и другими оценками корреляции. Это показывает, что для неоднородных распределений (смесей) различные меры корреляции могут давать принципиально разные результаты.
4) С увеличением объёма выборки дисперсия коэффициента Пирсона уменьшается, и его значение становится более устойчивым. Аналогично уменьшаются дисперсии коэффициентов Спирмена и квадрантного, однако их средние значения остаются положительными.

Выводы

1) Коэффициент Пирсона наиболее точно отражает линейную зависимость в двумерном нормальном распределении: его средние значения практически совпадают с заданными параметрами, а отклонения минимальны. При этом он чувствителен к выбросам и величине отклонений.
2) Коэффициенты Спирмена и квадрантный являются более устойчивыми к выбросам и отражают структуру основной массы данных. В случае смеси распределений они дают положительные значения (около 0.47 и 0.55 соответственно), несмотря на отрицательную линейную корреляцию, получаемую по коэффициенту Пирсона.
3) С увеличением объёма выборки оценки всех коэффициентов становятся более стабильными: их дисперсии уменьшаются, а средние значения сходятся к устойчивым величинам.
4) Эллипсы равновероятности хорошо описывают структуру двумерного нормального распределения, отражая направление и силу зависимости. Однако для смеси распределений они дают лишь приближённое представление, так как не учитывают наличие выбросов и неоднородность структуры данных.