Санкт-Петербургский Политехнический Университет
Высшая школа прикладной математики и вычислительной физики, ФизМех
01.03.02 Прикладная математика и информатика

Отчет по лабораторной работе № 6
"Линейная регрессия. Метод наименьших квадратов и наименьших модулей"

Выполнил студент гр. 5030102/30201 Аулова М. В.
Преподаватель Баженов А. Н.

Санкт-Петербург
2026

Постановка задачи

Задание:

1. Задать равномерные значения xi на отрезке $[-1.8, 2]$ с шагом 0.2 (20 точек).
2. Сгенерировать $yi = 2 + 2xi + \varepsilon i$, где $\varepsilon i \sim N(0, 1)$.
3. Оценить параметры a, b двумя методами:
    - Метод наименьших квадратов (МНК).
    - Метод наименьших модулей (МНМ).
4. Повторить пункты 1–3, добавив выбросы: $y1 \leftarrow y1 + 10$, $y20 \leftarrow y20 - 10$.

Цели и задачи:

- Сравнить устойчивость МНК и МНМ к выбросам.
- Построить графики регрессионных прямых и исходных данных.

Теоретическая часть

1. Модель простой линейной регрессии

Простая линейная регрессия представляет собой модель описания данных, в которой связь между переменными выражается уравнением:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, i = 1, \dots, n$$

где:

- x_i — заданные значения фактора;
- y_i — наблюдаемые значения отклика;
- β_0, β_1 — **неизвестные параметры**, подлежащие оцениванию;
- ε_i — независимые, нормально распределенные случайные величины $N(0, \sigma)$с нулевым математическим ожиданием и одинаковой дисперсией.

В данной модели предполагается, что весь разброс экспериментальных точек обусловлен только погрешностями измерения отклика y, в то время как погрешностями фактора x можно пренебречь.

2. Метод наименьших квадратов (МНК)

Наиболее распространенным методом оценивания параметров является **метод наименьших квадратов**. Его суть заключается в минимизации суммы квадратов остатков (рассогласования):

$$Q(\beta_0, \beta_1) = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2 \to \min_{\beta_0, \beta_1}$$

Оценки, реализующие этот минимум, называются **МНК-оценками**. Критерием оптимальности в данном случае выступает **l2-норма**.

Расчетные формулы для МНК-оценок:

Для нахождения оценок используются условия экстремума (равенство нулю частных производных), что приводит к системе нормальных уравнений. В результате получаются следующие формулы:

- **Коэффициент наклона:**

$$\hat{\beta}_1 = \frac{\overline{xy} - \bar{x}\bar{y}}{\overline{x^2} - (\bar{x})^2}$$

- **Свободный член:**

$$\hat{\beta}_0 = \bar{y} - \bar{x}\hat{\beta}_1$$

где $\overline{xy}$ — выборочная ковариация, $\overline{x^2}$ — средний квадрат x, $\bar{x}, \bar{y}$ — выборочные средние.

3. Робастные оценки и метод наименьших модулей (МНМ)

Классический МНК чувствителен к наличию выбросов. Для обеспечения **робастности** (устойчивости) оценок используется **метод наименьших модулей**, который минимизирует сумму абсолютных отклонений:

$$\sum_{i=1}^{n} | y_i - \beta_0 - \beta_1 x_i | \to \min_{\beta_0, \beta_1}$$

Этот метод минимизирует **l1-норму** разности между экспериментальными данными и значениями функции. Робастность МНМ объясняется тем, что он опирается на свойства медианы, которая менее чувствительна к экстремальным значениям на концах ряда, чем среднее арифметическое.

В отличие от МНК, для которого есть простые аналитические формулы, задача МНМ на практике решается с помощью численных методов. Чтобы не прибегать к сложным численным методам используем простейшую альтернативу для расчета робастных оценок коэффициентов, используя следующие формулы

- Вместо выборочных средних используются **выборочные медианы** (med x и med y).
- Вместо среднеквадратических отклонений — полумежквартильные размахи q_y*, q_x* = IQR_x / 2
- Вместо коэффициента корреляции Пирсона — **знаковый (квадрантный) коэффициент корреляции** rQ

Коэффициент знаковой корреляции

Сначала вычисляется коэффициент знаковой корреляции между переменными x и y:

$$r_Q = \frac{1}{n}\sum_{i=1}^{n} \operatorname{sgn}(x_i - \operatorname{med} x) \cdot \operatorname{sgn}(y_i - \operatorname{med} y),$$

Оценка коэффициента наклона

$$\hat{\beta}_1^R = r_Q \cdot \frac{q_y^*}{q_x^*}.$$

Оценка свободного члена

$$\hat{\beta}_0^R = \operatorname{med} y - \hat{\beta}_1^R \cdot \operatorname{med} x.$$

4. Оценка качества регрессии

Для количественной оценки точности полученных моделей в лабораторной работе используется **относительная погрешность** параметров:

$$\delta z = \frac{|\,\hat{z} - z\,|}{z} \cdot 100\%$$

где z — истинное значение параметра, а $\hat{z}$ — его приближенная оценка.

Реализация

Язык программирования: Python 3.14

Сторонние библиотеки:
numpy – генерация случайных выборок
matplotlib.pyplot – построение графиков
scipy.stats – теоретические распределения

Код: https://github.com/Maria9950/MatStat/tree/master/lab6

Результаты

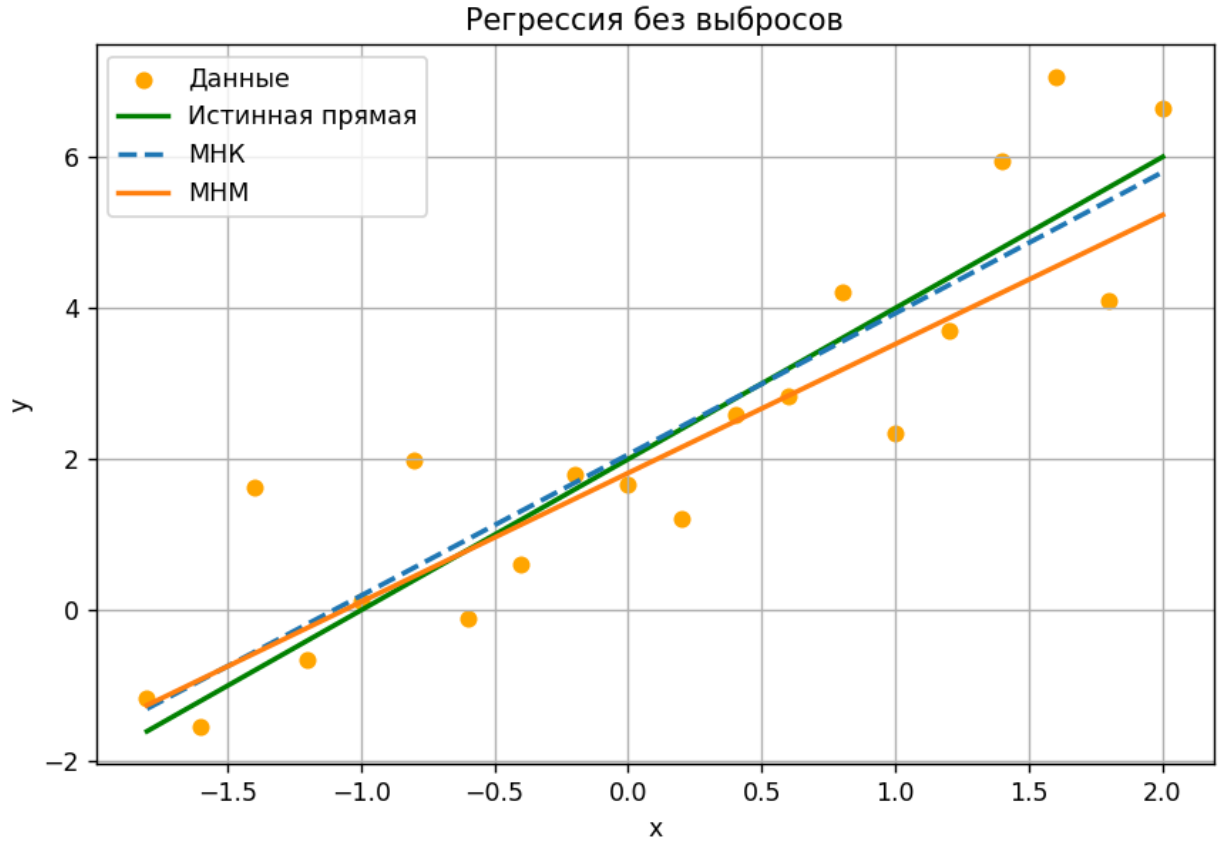
Регрессия без выбросов
Данные
Истинная прямая
МНК
МНМ
y
x
6
4
2
0
−2
−1.5
−1.0
−0.5
0.0
0.5
1.0
1.5
2.0

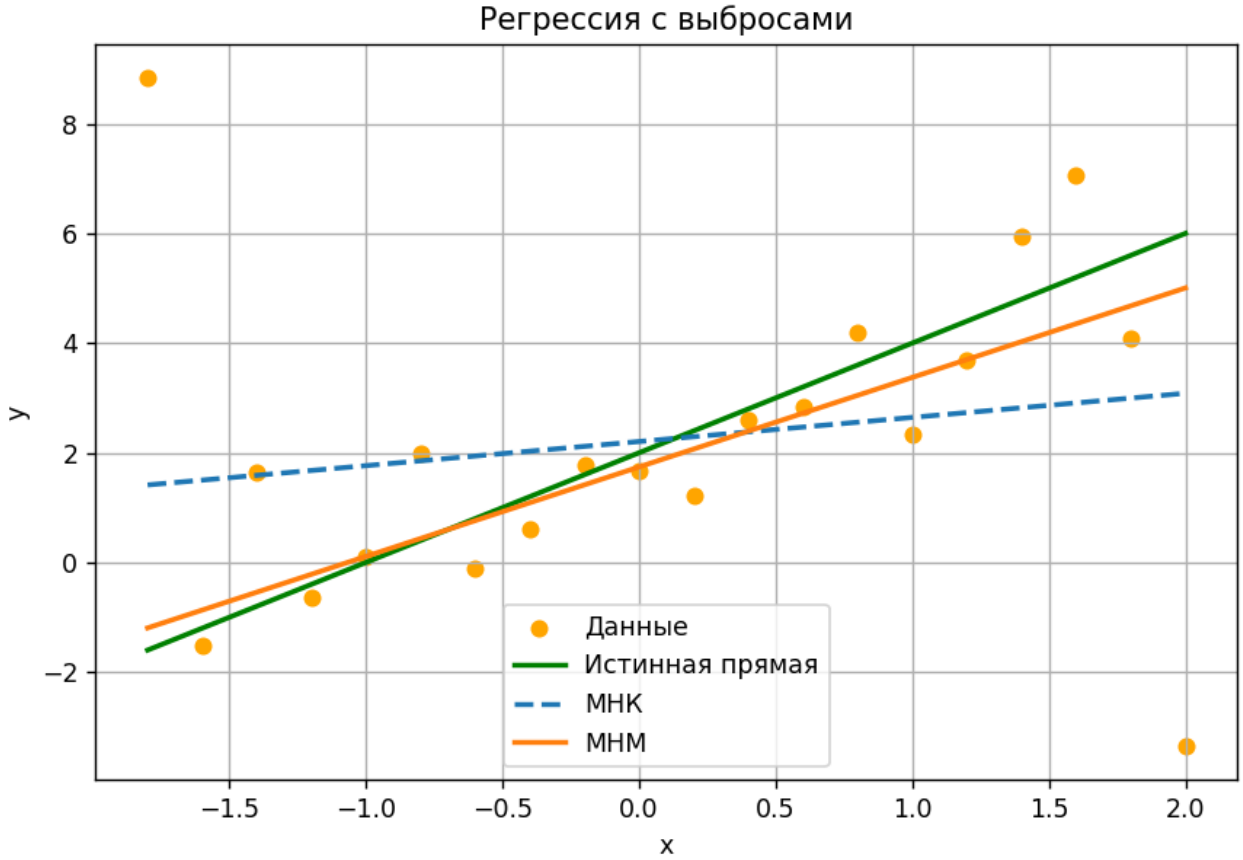
Регрессия с выбросами
Данные
Истинная прямая
МНК
МНМ
y
x
8
6
4
2
0
−2
−1.5
−1.0
−0.5
0.0
0.5
1.0
1.5
2.0

Без выбросов

Метод	a	Δa	δa, %	b	Δb	δb, %
МНК	2.061	0.061	3.06	1.869	0.132	6.57
МНМ	1.817	0.183	9.16	1.707	0.293	14.64

С выбросами

Метод	a	Δa	δa, %	b	Δb	δb, %
МНК	2.204	0.204	10.21	0.44	1.56	78
МНМ	1.742	0.259	12.92	1.632	0.368	18.4

Обсуждение

1. Данные без выбросов
На графике точки располагаются вдоль прямой y=2+2x с небольшим разбросом. Прямые МНК и МНМ близки к эталонной и хорошо описывают зависимость.
Численно: для МНК a≈2.061, b≈1.869 (погрешности 3.06% и 6.57%), для МНМ a≈1.817, b≈1.707 (9.16% и 14.64%). Оба метода работают корректно, при этом МНК даёт более точные оценки.

2. Данные с выбросами
После добавления выбросов прямая МНК заметно искажается: наклон уменьшается до b≈0.44, а ошибка достигает 78%. Это связано с высокой чувствительностью метода к большим отклонениям.
Метод МНМ остаётся более устойчивым: a≈1.742, b≈1.632, ошибки 12.92% и 18.4%. Прямая проходит через основную массу данных и сохраняет правильный наклон.

3. Сравнение устойчивости методов
В условиях отсутствия выбросов оба метода дают близкие и достаточно точные оценки параметров, при этом МНК показывает лучшую точность.
Однако при наличии выбросов метод МНК становится крайне чувствительным к аномальным значениям, что приводит к существенному искажению коэффициента наклона. Метод МНМ, напротив, остаётся устойчивым, поскольку минимизирует сумму абсолютных отклонений и в меньшей степени зависит от экстремальных наблюдений.
Таким образом, МНК является эффективным методом при нормальных ошибках, тогда как МНМ предпочтителен при наличии выбросов.

Выводы

В работе показано, что на данных без выбросов методы наименьших квадратов и наименьших модулей дают близкие и достаточно точные оценки параметров, при этом МНК демонстрирует несколько большую точность.

При наличии выбросов наблюдается существенное различие между методами: МНК оказывается чувствительным к аномальным значениям, что приводит к значительному искажению коэффициента наклона, тогда как МНМ сохраняет устойчивость и лучше описывает основную зависимость в данных.

Таким образом, результаты подтверждают, что метод наименьших модулей является более робастным и предпочтительным при наличии выбросов, в то время как метод наименьших квадратов эффективен при отсутствии аномальных значений.